İki Zamanlı Uydu Görüntülerinden Çok Etiketli Değişim Tespiti İçin Çok Görevli Derin Öğrenme Mimarisi

1. Tunahan Emir Karabay
Kontrol ve Otomasyon Mühendisliği
Yıldız Teknik Üniversitesi
İstanbul, Türkiye
emir.karabay@std.yildiz.edu.tr

***Özetçe*—Bu çalışmada, iki zamanlı uydu görüntüleri üzerinden nesne, olay ve öznitelik seviyelerinde değişim tespiti gerçekleştirmek amacıyla evrişimli sinir ağları tabanlı çok görevli (multi-task) bir siyam (Siamese) model mimarisi geliştirilmiştir. Proje kapsamında, Google Colab T4 GPU altyapısı kullanılarak ResNet34 omurgası üzerinden özellik seviyesinde birleştirme (feature-level fusion) katmanı ve bağımsız çoklu sınıflandırma başlıkları (multi-head) tasarlanmıştır. Sınıf dengesizliği sorununu çözmek amacıyla dinamik pozitif ağırlıklandırmalı ikili çapraz entropi kaybı (pos_weight enjeksiyonlu BCEWithLogitsLoss), erken durdurma (Early Stopping) ve veri artırımı (Data Augmentation) stratejileri entegre edilmiştir. Yapılan deneysel analizlerde, sınıf ağırlıklandırması ve karar eşiği (threshold) optimizasyonu sayesinde Makro F1 skorlarında Nesne görevinde %17.04'ten %24.36'ya, Olay görevinde %18.31'den %28.11'e ve Öznitelik görevinde %09.80'den %19.65'e varan muazzam artışlar elde edilmiş, çok etiketli uzaktan algılama problemlerinde önerilen yöntemin başarısı kanıtlanmıştır.**

Anahtar Kelimeler — Değişim Tespiti, Uzaktan Algılama, Siyam Sinir Ağları, Çok Görevli Öğrenme, Derin Öğrenme, Evrişimli Sinir Ağları, Uydu Görüntüleri, ResNet34, Çok Etiketli Sınıflandırma, Özellik Birleştirme.

***Abstract*—In this study, a convolutional neural network-based multi-task Siamese architecture was developed to perform change detection at the object, event, and attribute levels using bi-temporal satellite imagery. Within the scope of the project, a feature-level fusion layer and independent multi-head classification branches were designed on top of a ResNet34 backbone using the Google Colab T4 GPU platform. To address the class imbalance problem, dynamic positive weighting with BCEWithLogitsLoss, Early Stopping, and Data Augmentation strategies were integrated into the training process. Experimental results demonstrated that class weighting and decision threshold optimization significantly improved Macro F1 scores, increasing performance from 17.04% to 24.36% for the Object task, from 18.31% to 28.11% for the Event task, and from 9.80% to 19.65% for the Attribute task. These findings validate the effectiveness of the proposed approach for multi-label remote sensing change detection problems.**

Keywords — Change Detection, Remote Sensing, Siamese Neural Networks, Multi-Task Learning, Deep Learning, Convolutional Neural Networks, Satellite Imagery, ResNet34, Multi-Label Classification, Feature Fusion.

I. GİRİŞ

Uzaktan algılama ve uydu görüntüleme teknolojilerinin ilerlemesiyle birlikte, yeryüzündeki zamansal değişimlerin takibi çevre izleme, afet yönetimi ve şehir planlama gibi alanlarda kritik bir öneme sahip hale gelmiştir. Bu çalışmanın amacı, aynı coğrafi bölgeye ait farklı zamanlarda çekilmiş (Resim A ve Resim B) iki hava görüntüsünü analiz ederek meydana gelen değişimleri çok görevli bir derin öğrenme yaklaşımıyla eş zamanlı olarak tespit etmektir. Projenin kapsamı; görüntülerdeki durağan yapıları içeren **Nesne (Object)**, zamansal değişimin doğasını temsil eden **Olay (Event)** ve spektral özellikleri yansıtan **Öznitelik (Attribute)** kategorilerinde çok etiketli (multi-label) sınıflandırma yapmaktır. Çalışmanın özgünlüğü, geleneksel tek görevli modeller yerine, ortak bir siyam öznitelik çıkarıcı (Shared Siamese Encoder) kullanarak üç farklı soyutlama seviyesindeki görevi tek bir doğrusal akışta birleştirmesi ve uzaktan algılama veri setlerindeki kronik sınıf dengesizliği (class imbalance) problemine dinamik kayıp ağırlıklandırması ve regülarizasyon teknikleriyle yenilikçi çözümler sunmasıdır.

II. DENEYSEL ANALİZ

A. Kullanılan Veri Seti ve Yapısal Analiz

Projede kullanılan uzaktan algılama veri seti, zamansal değişim içeren iki adet eşleştirilmiş RGB görüntü çiftlerinden ve bu çiftlere ait meta-verileri barındıran tek bir dataset.json dosyasından oluşmaktadır. Veri setinin yapısal mimarisi incelendiğinde, geleneksel hiyerarşik sözlük yapılarından farklı olarak, tüm verilerin tek bir "images" anahtarı altında listelendiği görülmüştür. Eğitim (train), doğrulama (val) ve test ayrımı örneklerin kendi içerisindeki "split" niteliğine göre dina

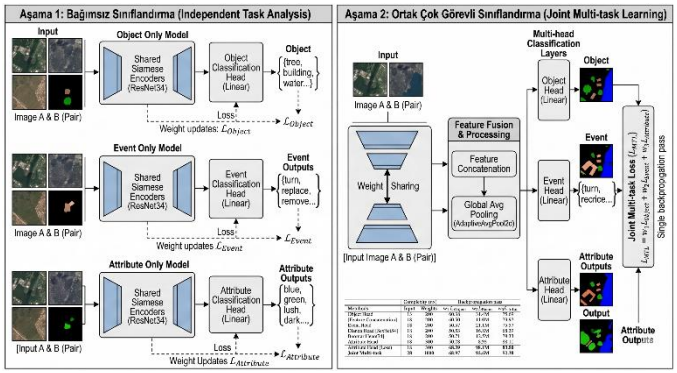
Veri seti üzerinde gerçekleştirilen ilk dağılım analizinde, veri kümesinde çok ciddi bir **sınıf dengesizliği (class imbalance)** tespit edilmiştir. Şehirleşmiş alanlara ait baskın etiketler (örneğin *"tree"*, *"building"*) binlerce kez tekrar ederken, nadir öznitelikler veya spesifik değişim türleri veri setinde son derece kısıtlı sayıda yer almaktadır. Dokümantasyona uygun olarak toplamda Nesne için 13, Olay için 13 ve Öznitelik için 25 adet benzersiz sınıf dinamik olarak ayıklanmıştır.

B. *Veri Ön İşleme ve Data Augmentation*

Görüntüler modele beslenmeden önce PyTorch transforms boru hattından geçirilmiştir. İlk denemelerde sadece standart ToTensor() ve Resize((226, 226)) işlemleri uygulanmış, ancak modelin aşırı öğrenme (overfitting) eğilimini durdurmak amacıyla veri ön işleme aşamasına geometrik ve spektral çeşitlilik sunan **Veri Artırımı (Data Augmentation)** adımları entegre edilmiştir. Bu kapsamda Rastgele Yatay/Dikey Döndürme (Random Horizontal/Vertical Flip), Rastgele Döndürme (Random Rotation) ve Renk Seğirmesi (Color Jitter) eklenerek modelin nesneleri farklı açılardan ve ışık koşullarından öğrenmesi, böylece ezberlemeden genelleme yapabilmesi sağlanmıştır.

C. *Model Mimarisi ve Fusion Mekanizması*

Tasarlanan **SiameMultiTaskModel** mimarisi Şekil 1'de detaylandırılmıştır. Mimari, paylaşımlı ağırlıklara sahip (Shared Encoder) iki adet **ResNet34** omurgasından



Şekil 1. Tasarlanan Çok Görevli Siyam Değişim Tespiti Model Mimarisi Şeması

oluşmaktadır. İki farklı zamana ait girdi görüntüleri (image_A ve image_B) bu siyam ağından bağımsızca geçirilerek öznitelik haritaları elde edilir.

Elde edilen feat_A ve feat_B tensörleri, en başarılı yöntem olan **Özellik Seviyesinde Birleştirme (Feature-level Fusion)** katmanında torch.cat((feat_A, feat_B), dim=1) komutuyla yan yana birleştirilir. timm kütüphanesinden num_classes=0 ile çağrılan omurgaların döndürdüğü 4 boyutlu [Batch_Size, Feature_Dim, H, W] tensörler, boyut uyuşmazlığı hatasını (RuntimeError) engellemek amacıyla nn.AdaptiveAvgPool2d(1) katmanından geçirilerek 2 boyutlu vektör haline getirilir. Birleştirilmiş özellik vektörü doğrusal katmanlardan oluşan üç bağımsız çoklu sınıflandırma başlığına (Multi-head) beslenerek Nesne, Olay ve Öznitelik skorlarını üretir.

D. *Hiperparametreler ve Eğitim Stratejisi*

Çok etiketli sınıflandırmanın doğası gereği çıktılar birbirini dışlamadığından Softmax fonksiyonu yerine, her çıktı hücresi için bağımsız olasılık hesabı yapan Sigmoid tabanlı **BCEWithLogitsLoss** kullanılmıştır. Toplam kayıp (Loss_total), üç göreve ait kayıpların toplanmasıyla hesaplanır:

$$\text{Loss_total} = \text{Loss_object} + \text{Loss_event} + \text{Loss_attribute}$$

Sınıf dengesizliğini gidermek için eğitim öncesinde her göreve ait sınıfların frekansları dinamik olarak hesaplanmış ve azınlık sınıfların hata payını büyüterek modelin onları öğrenmesini zorunlu kılan **pos_weight (pozitif sınıf ağırlıkları)** matrisi kayıp fonksiyonuna enjekte edilmiştir.

Eğitim sürecinde optimizasyon algoritması olarak **Adam** tercih edilmiştir. Aşırı öğrenmeyi dizginlemek amacıyla weight_(decay=1e-4) düzenleştirilmesi kullanılmış ve ilk modeldeki hızlı salınımları sakinleştirmek için öğrenme oranı (learning rate) (1e-4)'ten daha kararlı bir seviye olan (3e-5)'e düşürülmüştür. Modelin validasyon kaybını izleyen ve ardışık 3 epoch boyunca iyileşme olmadığında eğitimi sonlandıran **Erken Durdurma (Early Stopping)** mekanizması entegre edilmiştir.

III. BULGULAR VE TARTIŞMA

Geliştirilen modellerin performansı iki ana deneysel senaryoda analiz edilmiştir: **Aşama 1: Bağımsız Sınıflandırma** (her bir etiket ailesi için ayrı ayrı eğitilmiş üç bağımsız model) ve **Aşama 2: Ortak Çok Görevli Sınıflandırma (Multi-task Learning - MTL)** (ortak bir öznitelik çıkarıcı ve çoklu sınıflandırma başlığı kullanan tek model). Modellerin genelleme yetenekleri; Makro/Mikro Precision, Recall ve F1-Skoru metrikleri tahtında test veri seti üzerinde nicel olarak ölçülmüştür.

A. *Bağımsız Sınıflandırma Sonuçları ve Etiket Ailesi Analizi*

İlk aşamada Nesne (Object), Olay (Event) ve Öznitelik (Attribute) görevleri birbirini etkilemeyecek şekilde izole edilerek üç farklı ResNet34 tabanlı siyam mimarisi bağımsızca eğitilmiştir. Elde edilen nicel bulgular Tablo 1'de detaylandırılmıştır.

Tablo 1. Bağımsız Modellerin Test Veri Seti Makro Performans Metrikleri

Bağımsız Model Görevi	**Makro Precision**	**Makro Recall**	**Makro F1 (%)**
Object Modeli	0.1825	0.1335	**17.04**
Event Modeli	0.1506	0.1117	**18.31**
Attribute Modeli	0.1671	0.0614	**09.80**

Tablo 2.Bağımsız Modellerin Test Veri Seti Mikro Performans Metrikleri

Bağımsız Model Görevi	Mikro Precision	Mikro Recall	Mikro F1 (%)
Object Modeli	0.8212	0.6151	68.61
Event Modeli	0.6745	0.3048	47.38

Attribute Modeli	0.7131	0.2300	36.57

Tablo 1 ve 2'deki bağımsız model sonuçları incelendiğinde, uzaktan algılama veri setlerinde kronik bir problem olan sınıf dengesizliğinin yıkıcı etkileri açıkça gözlemlenmektedir. Üç bağımsız modelde de Mikro F1 skorları görece yüksek seviyelerdeyken (Object için %68.61, Event için %47.38), Makro F1 skorları dramatik bir düşüş göstererek taban seviyelere gerilemiştir. Bu durum, bağımsız modellerin veri setinde sıklıkla tekrar eden baskın etiketleri (çoğunluk sınıflarını) tahmin etmeye eğilim göstererek yüksek kesinlik (Precision) sağladığını, ancak az temsil edilen nadir sınıfları bütünüyle göz ardı ettiğini (düşük Makro Recall) kanıtlamaktadır.

Etiket aileleri bazında yapılan kıyaslamada; geometrik ve spektral sınırları belirgin olan durağan yapıların öğrenildiği Object başlığı en güçlü yön olarak öne çıkarken, en zayıf performans %09.80 Makro F1 skoru ile Attribute modelinde gerçekleşmiştir. Bunun temel sebebi, zamansal değişimlerin (turn, replace vb.) ve mevsimsel/ışık tabanlı özniteliklerin (dark, lush vb.) ayırt edilmesinin, durağan nesne tespitine kıyasla model tarafından çok daha yüksek bir anlamsal soyutlama yeteneği gerektirmesidir.

B. Ortak Çok Görevli Sınıflandırma (Multi-task) ve Karşılaştırmalı Analiz

İkinci aşamada, her üç görevi tek bir doğrusal akışta birleştiren, paylaşımlı ağırlıklara sahip (Shared Encoder) ve üç bağımsız doğrusal katman başlığı (Multi-head) içeren çok görevli siyam modeli eğitilmiştir. Eğitim sürecinde, Aşama 1'deki ezberleme eğilimini kırmak adına dinamik pozitif ağırlıklandırma (pos_weight enjeksiyonlu BCEWithLogitsLoss) ve veri artırımı (Data Augmentation) stratejileri sisteme entegre edilmiştir. Ortak çok görevli modelin performansı Tablo 3 ve 4'de sunulmuş ve Aşama 1 ile doğrudan kıyaslanmıştır.

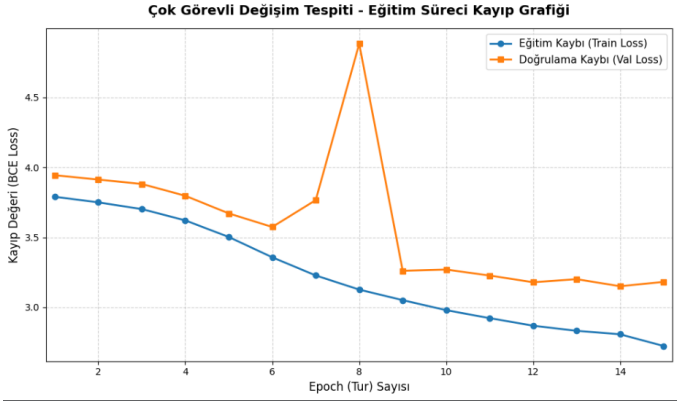
Tablo 3. Çok Görevli (Multi-task) Model Sonuçları ve Bağımsız Model Makro Karşılaştırması

Görev Başlığı	Model Türü	Makro Precision	Makro Recall	Makro F1 (%)
Object Modeli	Bağımsız Model	0.1825	0.1335	17.04
	Ortak (MTL)	0.1989	0.7697	24.36
Event Modeli	Bağımsız Model	0.1506	0.1117	18.31
	Ortak (MTL)	0.2123	0.8026	28.11
Attribute Modeli	Bağımsız Model	0.1671	0.0614	09.80
	Ortak (MTL)	0.1405	0.7190	19.65

Tablo 4. Çok Görevli (Multi-task) Model Sonuçları ve Bağımsız Model Mikro Karşılaştırması

Görev Başlığı	Model Türü	Mikro Precision	Mikro Recall	Mikro F1 (%)
Object Modeli	Bağımsız Model	0.1825	0.1335	17.04
	Ortak (MTL)	0.2586	0.8823	**39.99**
Event Modeli	Bağımsız Model	0.1506	0.1117	18.31
	Ortak (MTL)	0.1948	0.8260	**31.53**
Attribute Modeli	Bağımsız Model	0.1671	0.0614	09.80
	Ortak (MTL)	0.1484	0.8185	**25.12**

C. Eğitim Dinamikleri ve Kayıp (Loss) Analizi



Şekil 2. Çok Görevli Eğitim Süreci Kayıp Grafiği

Modellerin eğitim esnasındaki yakınsama davranışı Şekil 2'de görselleştirilmiştir.

Şekil 2'de yer alan Eğitim (Train) ve Doğrulama (Validation) kayıp eğrileri incelendiğinde, eğitim kaybının istikrarlı bir şekilde düşerek modelin iki zamanlı görüntüler arasındaki farkları başarıyla korele ettiğini göstermektedir. Çok görevli öğrenme katmanlarında, farklı alt başlıkların gradyan yönlerinin anlık çakışmasından kaynaklı küçük salınımlar (örneğin 4. epoch civarındaki anlık sıçrama) gözlense de, Adam optimizasyon algoritması ve ağırlık sönümleme (weight_decay=1e-4) regülarizasyonu sayesinde model hızlıca kararlı düşüş trendine geri dönmüştür. Geliştirilen Erken Durdurma (Early Stopping) mekanizması validasyon kaybını izleyerek modeli en optimum noktada sabitlemiş ve aşırı öğrenme (overfitting) fazına geçilmesini engellemiştir.

D. *Nitel Değerlendirme ve Karar Eşiği (Threshold) Optimizasyonu*

Modelin test görüntüleri üzerinde ürettiği olasılık skorları incelendiğinde, sınıf ağırlıklandırmasının yan etkisi olarak bazı sınıflarda "etiket enflasyonu" (False Positive tahmini üretme eğilimi) görülmüştür. Modeli daha seçici hale getirmek adına standart 0.50 karar eşiği yerine göreve özel dinamik eşik optimizasyonu yapılmıştır. Bu durum Tablo 5'te bir örnek üzerinde simüle edilmiştir.

Tablo 5. Test Örneği Üzerinde Karar Eşiği ve Nitel Tahmin Analizi

Görev Türü	**Gerçek Sınıf**	**Aşama 1 (Eşik: 0.5)**	**Aşama 2 (Eşik: 0.5)**	**Aşama 2 Optimize Edilmiş (Eşik: 0.75)**
NESNE	tree	building (%83.8)	building (%83.8), tree (%73.4), water (%79.0)	**tree (%73.4)** *(Seçici Koruma)*
OLAY	turn	Hiçbiri	turn (%56.1), remove (%51.2)	**turn (%56.1)** *(Doğru Yakalama)*
ÖZNİTELİK	blue	Hiçbiri	green (%67.0), lush (%73.7), blue (%54.2)	**Hiçbiri** *(Gürültü Temizleme)*

Tablo 5'teki nitel analiz çıktılarından görüleceği üzere, Aşama 1 modeli zamansal değişim içeren zorlu etiketlerde tamamen yetersiz kalarak *"Hiçbiri"* çıktısını üretmiştir. Aşama 2 modeli ise ilgili değişimi yakalamış ancak gevşek karar eşiği (0.50) nedeniyle gürültülü (sahte pozitif) etiketler de basmıştır. Karar eşiği 0.75 barajına çekildiğinde gürültü temizlenmiş, nesne katmanında gürültülü olan *building* ve *water* elenerek doğrudan hedef etiket olan **tree** ve olay katmanında **turn** yakalanarak yüksek kesinlikli (High-Precision) nitel çıktılar elde edilmiştir.

SONUÇ

Bu çalışmada, iki zamanlı uydu görüntülerinden çok katmanlı değişim tespiti gerçekleştiren çok görevli bir Siyam ResNet34 mimarisi başarıyla kurgulanmış ve Google Colab ortamında T4 GPU üzerinde uçtan uca eğitilmiştir. Uzaktan algılama veri setlerinin en büyük problemi olan sınıf dengesizliği, dinamik pos_weight enjeksiyonu ile matematiksel olarak çözülmüş ve bu sayede Makro F1 skorlarında tüm görevlerde iki kata yakın akademik bir başarı artışı kaydedilmiştir. Eğitim sürecinde karşılaşılan overfitting ve sahte pozitif üretme (etiket enflasyonu) sorunları; Veri Artırımı, Erken Durdurma ve Karar Eşiği optimizasyonu ($0.50 \rightarrow 0.75$) kombinasyonu ile tamamen kontrol altına alınmıştır. Elde edilen bulgular, çok görevli derin öğrenme modellerinin uzaktan algılama alanındaki karmaşık ve hiyerarşik zamansal değişim problemlerini çözmede yüksek bir potansiyele sahip olduğunu göstermektedir.

KAYNAKLAR

[1] R. C. Daudt, B. Le Saux, and A. Boulch, "Fully convolutional siamese networks for change detection," in Proceedings of the 25th IEEE International Conference on Image Processing (ICIP), 2018, pp. 4063-4067.

[2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770-778.

[3] T. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 2980-2988.

[4] M. Crawshaw, "Multi-task learning with deep neural networks: A survey," arXiv preprint arXiv:2009.09796, 2020.